רקע מתמטי 1.1

שאלה 1.1.1

1) נחשב AA^T ו- A^TA:

$$AA^T = \begin{pmatrix} 2 & 0 \\ 0 & 6 \end{pmatrix} \qquad A^TA = \begin{pmatrix} 2 & 0 & 2 \\ 0 & 2 & -2 \\ 2 & -2 & 4 \end{pmatrix}$$

- עבור AA^T: ע"ע-ים הם $\lambda = 2,6$ עם ו"ע-ים $\begin{pmatrix}1\\0\end{pmatrix}, \begin{pmatrix}0\\1\end{pmatrix}$.
- עבור A^TA: $\lambda = 2,6,0$ עם ו"ע מנורמלים לפי גודל ע"ע:

$$V_1 = \begin{pmatrix} \frac{\sqrt{6}}{6} \\ \frac{-\sqrt{6}}{6} \\ \frac{\sqrt{6}}{3} \end{pmatrix} \quad V_2 = \begin{pmatrix} \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \\ 0 \end{pmatrix} \quad V_3 = \begin{pmatrix} -\frac{\sqrt{3}}{3} \\ \frac{\sqrt{3}}{3} \\ \frac{\sqrt{3}}{3} \end{pmatrix}$$

ולכן, פירוק SVD

$$A = U \Sigma V^T$$

כאשר:

$$U = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

$$V = \begin{pmatrix} \sqrt{6} & 0 & 0 \\ 0 & \sqrt{2} & 0 \end{pmatrix}$$

$$V^T = \begin{pmatrix} | & | & | \\ V_1 & V_2 & V_3 \\ | & | & | \end{pmatrix}^T$$

2) נכתוב

$$V=\begin{pmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{pmatrix} \quad u=\begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_m \end{pmatrix}$$

ולכן המכפלה החיצונית היא:

$$A=\begin{pmatrix} v_1u_1 & v_1u_2 & \cdots & v_1u_m \\ & & \vdots & \\ v_nu_1 & v_nu_2 & \cdots & v_nu_m \end{pmatrix}$$

נשים לב כי $Row_i A = v_i(u_1\ u_2 \dots u_m)$

כלומר כל שורה i היא מכפלת הסקלר v_i בוקטור השורה $(u_1 \dots u_m)$

ולכן דרגת המטריצה היא 1 בהנחה שוקטור השורה שונה מוקטור האפס.

3) נניח כעת

$$X=\sum_{k=1}^{n}\alpha_k u_k$$

$$\underset{\substack{\uparrow \\ \text{הגדרת } X}}{\langle X|u_i\rangle} = \left\langle \sum_{k=1}^{n}\alpha_k u_k \middle| u_i \right\rangle$$

$$\underset{\text{לינאריות}}{=} \sum_{k=1}^{n}\alpha_k\langle u_k|u_i\rangle$$

מכיוון ש- $\{u_1,\dots,u_n\}$ בסיס א"נ נקבל

$$\langle u_k,u_i\rangle=\begin{cases}1 & k=i\\ 0 & k\neq i\end{cases}$$

ולכן רב האברים יתאפסו כאשר $k\neq i$ ולכן נקבל

$$\sum_{k=1}^{n}\alpha_k\langle u_k|u_i\rangle=\alpha_i\overset{1}{\langle u_i|u_i\rangle}=\alpha_i$$

$$\Rightarrow \boxed{\langle X,u_i\rangle=\alpha_i}$$

(4

$$x = \begin{bmatrix} 3 \\ -4 \\ 1 \\ 2 \end{bmatrix}$$

(i) ℓ_1:

$$\|x\|_1 = 3 + |-4| + 1 + |-2| = 10$$

(ii) ℓ_2: $\|x\|_2 = \sqrt{3^2 + (-4)^2 + 1^2 + (-2)^2} = \sqrt{30}$

(iii) ℓ_∞: $\|x\|_\infty = \max(|3|, |-4|, 1, |-2|) = 4$

ℓ_∞ היא הנורמה עם הערך הכי קטן כי לוקחת
את הקורדינטה המקסימלית למרות ℓ_2 ו ℓ_1 אשר
מבצעים
סוכמים אותה הפעולה על כל הקורדינטות.

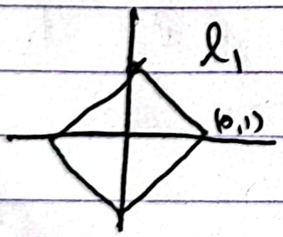

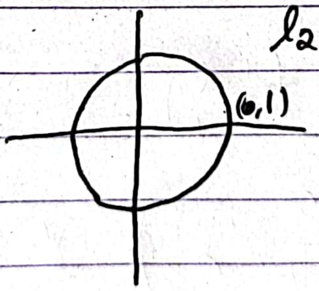

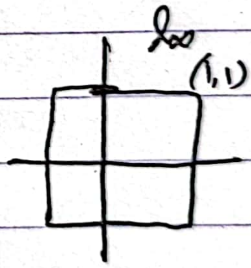

1.1.2

(b)

$$L(\sigma) = \frac{1}{2}\|f(\sigma) - y\|^2$$

נגדיר $z(\sigma) = f(\sigma) - y$

וכיל מכיוון ש-:

$$L(\sigma) = \frac{1}{2}\|z(\sigma)\|^2 = \frac{1}{2} z(\sigma)^T z(\sigma)$$

$$\nabla_\sigma L(\sigma) = \nabla_\sigma \left[\frac{1}{2} z(\sigma)^T z(\sigma)\right] = [\nabla_\sigma z(\sigma)]^T z(\sigma)$$

אבל מתקיים כי $\nabla_\sigma z(\sigma) = \nabla_\sigma f(\sigma)$

לכן:

$$\nabla_\sigma L(\sigma) = [\nabla_\sigma f(\sigma)]^T [f(\sigma) - y]$$

כלומר

$$\nabla_\sigma L(\sigma) = J_f(\sigma)^T (f(\sigma) - y)$$

(c)

$$S(x)_j = \frac{e^{x_j}}{\sum_{l=1}^{k} e^{x_l}}$$

נגדיר $z_j = S(x)_j$! $Z = \sum_{l=1}^{k} e^{x_l}$

היעקוביאן הינו מטריצה $k \times k$ כך שבמקום (i,j)
ישנה הנגזרת החלקית $\frac{\partial z_j}{\partial x_i}$

$$\frac{\partial z_j}{\partial x_i} = \frac{\partial (e^{x_j})}{\partial x_i}\frac{1}{Z} + e^{x_j}\frac{\partial \left(\frac{1}{Z}\right)}{\partial (x_i)} =$$

$$= \begin{cases} \frac{e^{x_j}}{Z} - e^{x_j}\cdot\frac{1}{Z^2}\frac{\partial Z}{\partial x_i} & i=j \\ -e^{x_j}\cdot\frac{1}{Z^2}\frac{\partial Z}{\partial x_i} & \text{אחרת} \end{cases}$$

נחשב כי:

$$\frac{\partial Z}{\partial x_i} = e^{x_i}$$

נקבל:

$$\frac{\partial z_j}{\partial x_i} = \begin{cases} \frac{e^{x_j}}{Z} - \frac{e^{x_j}e^{x_i}}{Z^2} & i=j \\ -\frac{e^{x_j}}{Z^2}\cdot e^{x_i} & i\neq j \end{cases}$$

נשים לב כי $\frac{e^{x_j}}{Z} = z_j$, $\frac{e^{x_i}}{Z} = z_i$

$$\frac{\partial z_j}{\partial x_i} = z_j(\mathbb{1}_{ij} - z_i)$$

$$\mathbb{1}_{ij} = \begin{cases} 1 & i=j \\ 0 & i\neq j \end{cases}$$

ולכן נגדיר מטריצה, נקבל

$$J_S(x) = D - zz^T$$

1.2 Linear regression

1.2.1

5. (a) צ"ל $Ker(X)=Ker(X^TX)$:

$\subseteq$:

אם $v\in Ker(X)$ אזי $Xv=0$

ונכפיל ב-X^T משמאל ונקבל

$X^TXv=X^T0=0$

ולכן $v\in(X^TX)$

$\supseteq$:

אם $v\in Ker(X^TX)$

נחשב את הנורמה לפי המרחב האוקלידי ונקבל

$\langle Xv|Xv\rangle = v^TX^TXv = v^T0 = 0_V$

כלומר הנורמה של Xv היא 0. וזה מתקיים

אם"ם $Xv=0$ כלומר $v\in Ker(X)$

(b) **$\subseteq$:**

יהי $w\in Im(A^T)$ אזי $w=A^Tz$

עבור z כלשהו

לכן $v\in Ker(A)$ מתקיים $Av=0$

ולכן

$\langle w|v\rangle = \langle A^Tz,v\rangle = \langle z,Av\rangle = \langle z,0\rangle = 0$

ולכן w אורתוגונלי לכל איבר ב-$Ker(A)$

ולכן $w\in Ker(A)^{\perp}$

~~$\supseteq$: יהי $w\in Ker(A)^{\perp}$ עבור $A^Tz=w$ מערכת משוואות~~

~~לפי משפט הפירוק, מתקיים $Col(A) \oplus Ker(A)$~~

1.2.1

5.b

ניקח $w \in \ker(A)^{\perp}$

כלומר לכל x, $Ax=0$ מתקיים:
$\langle w,x\rangle=0$

אפשר לנסח את $Ax=0$ הדיח? משוואות
A לפי שורות $\mathrm{Im}(A^T) = \mathrm{row}(A)$!
$\mathrm{Im}(A^T) \perp \ker(A)$
הם מהווים בסיס ל- $\ker(A)^{\perp}$.
לכן קיים z כך ש-
$w = A^T z$

$w \in \mathrm{Im}(A^T)$ כנדרש

5.c

⇐:

נניח $y \perp \ker(X^T)$
מכיוון ש- $\ker(X^T)$ הוא המשלים האורתוגונלי
ל- $\mathrm{Im}(X)$ נקבל $y \in \mathrm{Im}(X)$
ולכן יש לנו פתרון יחיד w_0 כך ש-
$Xw_0 = y$
ומכך ש- $\ker(X) \neq \{0\}$ גם $X(w_0+w)=0$
עבור w כלשהו, ולכן יש ∞ פתרונות.

⇒:

אם ל- $Xw=y$ יש ∞ פתרונות
ולכן יש פתרון $y \in \mathrm{Im}(X)$
ולפי משפט באלגברה $\mathrm{Im}(X) \perp \ker(X^T)$
ולכן $y \perp \ker(X^T)$ ∎

ו.ב.1

ס.5:

ניקח. $A=X$ מניוון שלו עמודה ב X^T

נמצאות כי $Im(X^T)=Col(X^T)$, ובהינתן $b=X^Ty$

נקבל כי $b\in Im(X^T)$

ומתקיים $Im(X^T)=Ker(X)^\perp$

ולכן $b\perp Ker(X)$

ולפי קודם ($Ker(X)=Ker(X^TX)$)

נקבל כי $b\perp Ker(X^TX)$

~~ולכן~~ ונקבל שיש לפחות פתרון

אחד ל- $X^TXw=b$

- אם X^TX הפיכה אז הפתרון (יחיד)

$$w=(X^TX)^{-1}X^Ty$$

- אם X^TX סינגולרית אז לכל $v\in Ker(X^TX)$

נקבל:

$$X^TX(w_0+v)=X^TXw_0+X^TXv=b+0=b$$

6) לפי ההגדרה $X^+=V\Sigma^{-1}U^T$

כאשר $$\Sigma^{-1}=\begin{pmatrix}\frac{1}{\sigma_1} & & \\ & \ddots & \\ & & \frac{1}{\sigma_d}\end{pmatrix}$$

ולכן $w^*=X^+y=V\Sigma^{-1}U^Ty$

מצד שני:

$$X^TX=(U\Sigma V^T)^T(U\Sigma V^T)=V\Sigma U^TU\Sigma V^T=V\Sigma^2V^T$$

Σ^2 אלכסונית, positive definite! , X^TX הפיכה

!מתקיים!

$$(X^TX)^{-1}=V\Sigma^{-2}V^T/X^T$$

(נכפיל ב y ונקבל:) $$(X^TX)^{-1}X^T=(V\Sigma^{-2}V^T)(V\Sigma U^T)=V\Sigma^{-1}U^T=X^+$$

$$(X^TX)^{-1}X^Ty=X^+y$$

הוכחנו ■

Regression model:
I adjusted the feature space so that no house in the dataset is renovated at year 0, and no house has 0 bedrooms nor 0 bathrooms. As well i have removed the entries in the response vector where the price is negative and removed duplicate entries in the dataset as well as removing when there's a null value in a certain feature.
I have also filtered out information not related to the price (i.e: id,. Long, lat …)

The lowest correlation feature is condition:

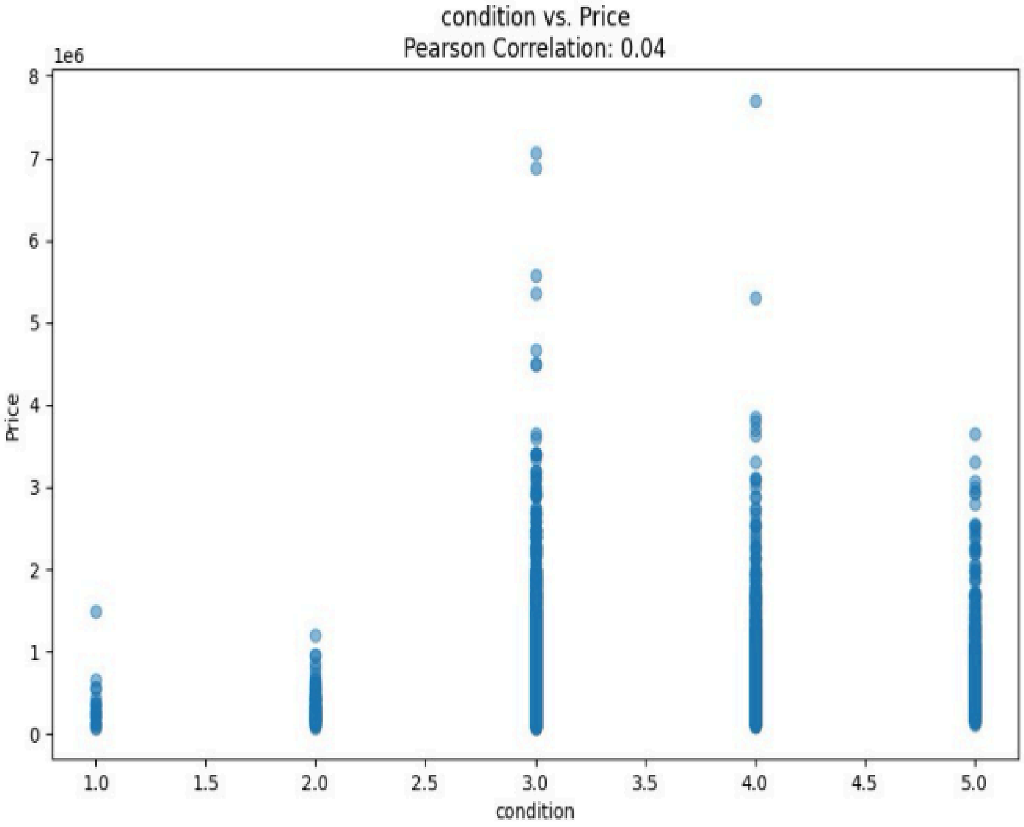

The highest Pearson correlation feature is sqft_living:
It is understood that the more the Pearson correlation is closest to 1, then the feature is correlated with the price.

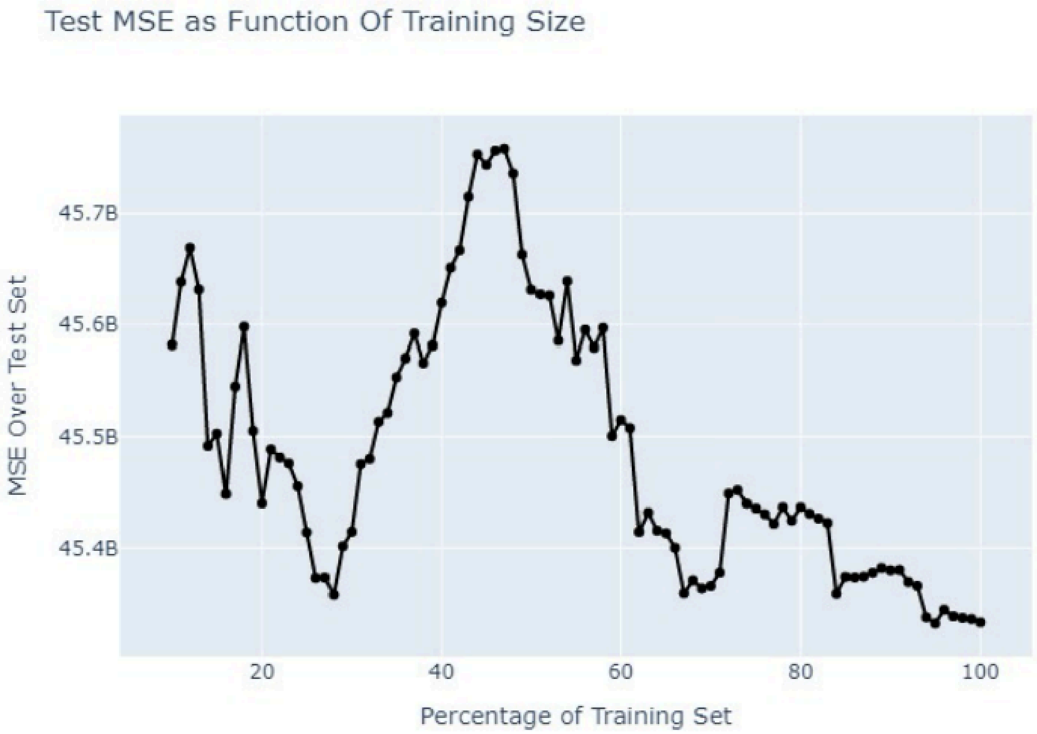

We can see that when taking p% of the training set and p<=100, and we train it for p%, 10 times and plot the mean out of those 10 times, we get that the more percentage we train, the more the MSE converges to a value between 45.5B and 45.4B which mean the error rate tends to be in a fixed interval.

Polynomial fitting:

The dots in the first graph all form the same smooth wave each year: temps rise through spring, hit their high point around day 200, then level off and fall again as winter comes. A simple curve (like a U-shape from a degree-2 polynomial) can’t show that little flat part on top, so using a 3rd- or 4th-degree polynomial makes more sense.

The bar chart tells us how much temps jump around each month. Summer (June-September) is pretty steady, so our model should do well there. Spring, especially March-April, is much more up-and-down, so predictions in those months will likely be worse—even though the train and test data come from the same place

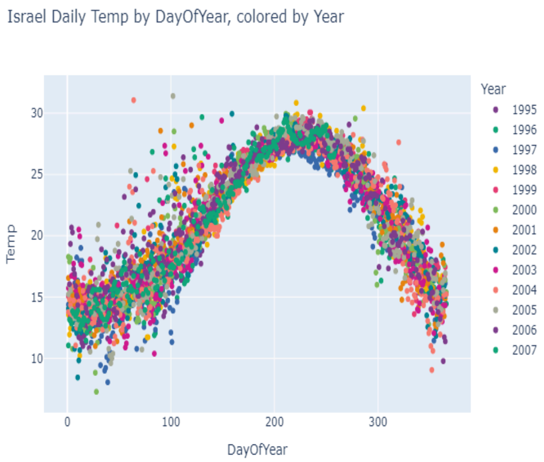

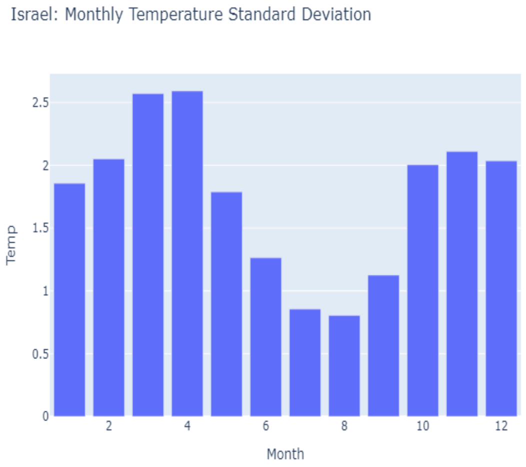

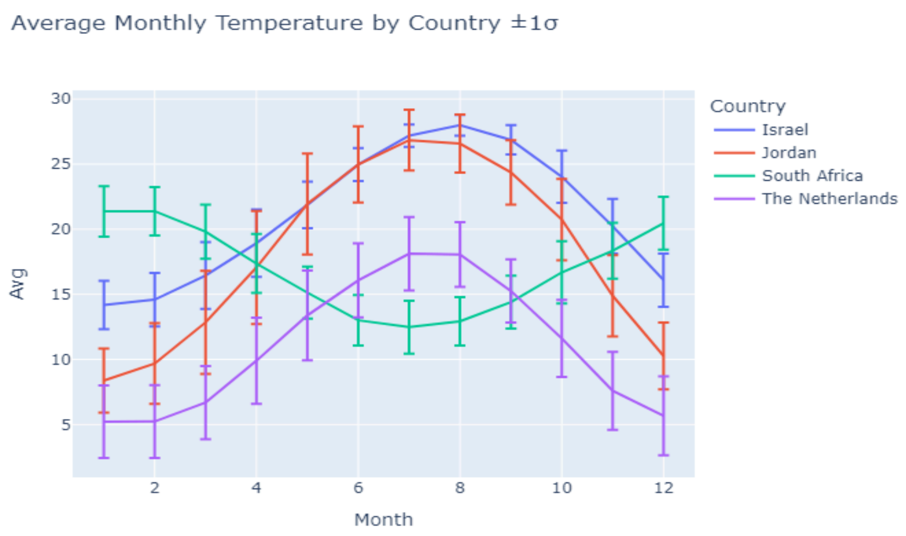

The figure makes it clear that every country has its own yearly temperature pattern:

- Israel vs. Jordan – The red (Jordan) and blue (Israel) curves rise and fall together, so a model trained on Israel should work fairly well for Jordan.

- The Netherlands – The purple curve has almost the same shape as Israel's, but it sits about 10 °C lower the whole year. We could probably reuse Israel's model if we just shift its intercept downward.

- South Africa – The green line is flipped and gentler: it's warm when Israel is cool and vice-versa, and its peaks and valleys are smaller. An Israel-based model would struggle here.

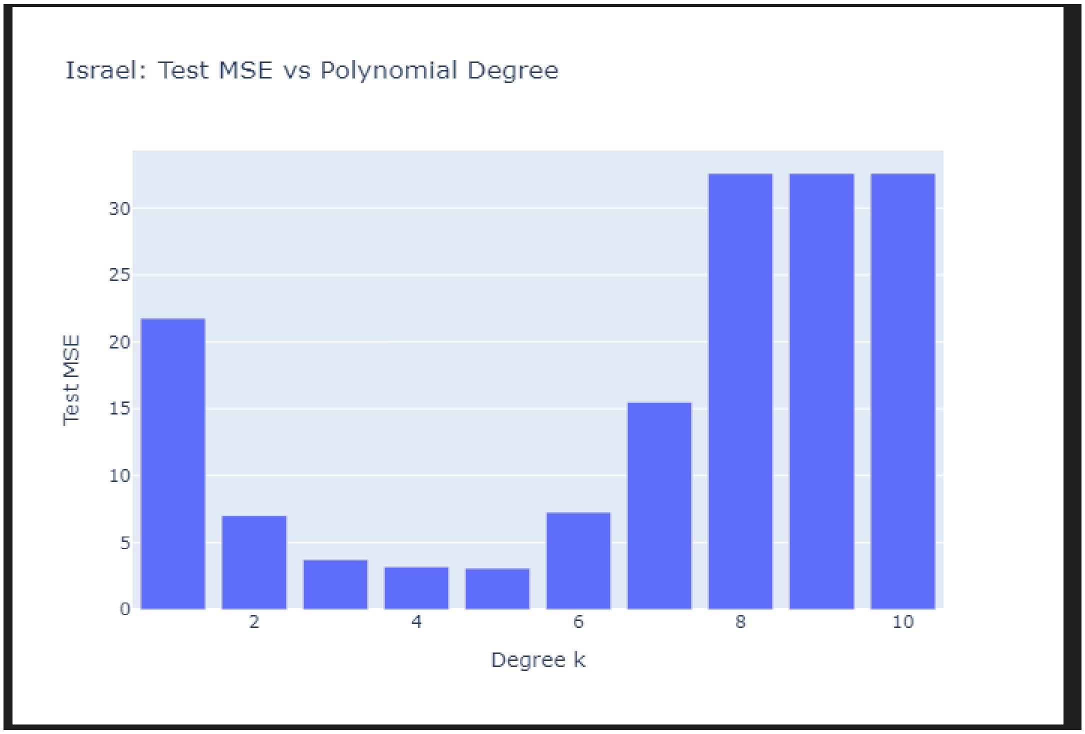

The model fitted with k = 5 achieved the lowest test error.